AI VIET NAM
@aivietnam.edu.vn

AI VIET NAM – AI COURSE 2025

LLMs Series: Reasoning LLMs

Dương Trường Bình Dương Đình Thắng Đinh Quang Vinh

I. Giới thiệu

Reasoning large language models (Reasoning LLMs) hay các mô hình LLM *"suy luận"*, là các mô hình ngôn ngữ lớn có khả năng mô phỏng quy trình tư duy logic và giải quyết vấn đề theo từng bước rõ ràng, từ việc trích xuất, liên kết các luận điểm đến diễn giải chi tiết trước khi đưa ra kết quả cuối cùng. Các mô hình như OpenAI o1 hay DeepSeek-R1 đã chứng tỏ thành công ấn tượng khi triển khai *khả năng suy luận (reasoning capabilities)* vào các mô hình ngôn ngữ lớn, nâng cao cả độ chính xác lẫn khả năng giải thích của kết quả.

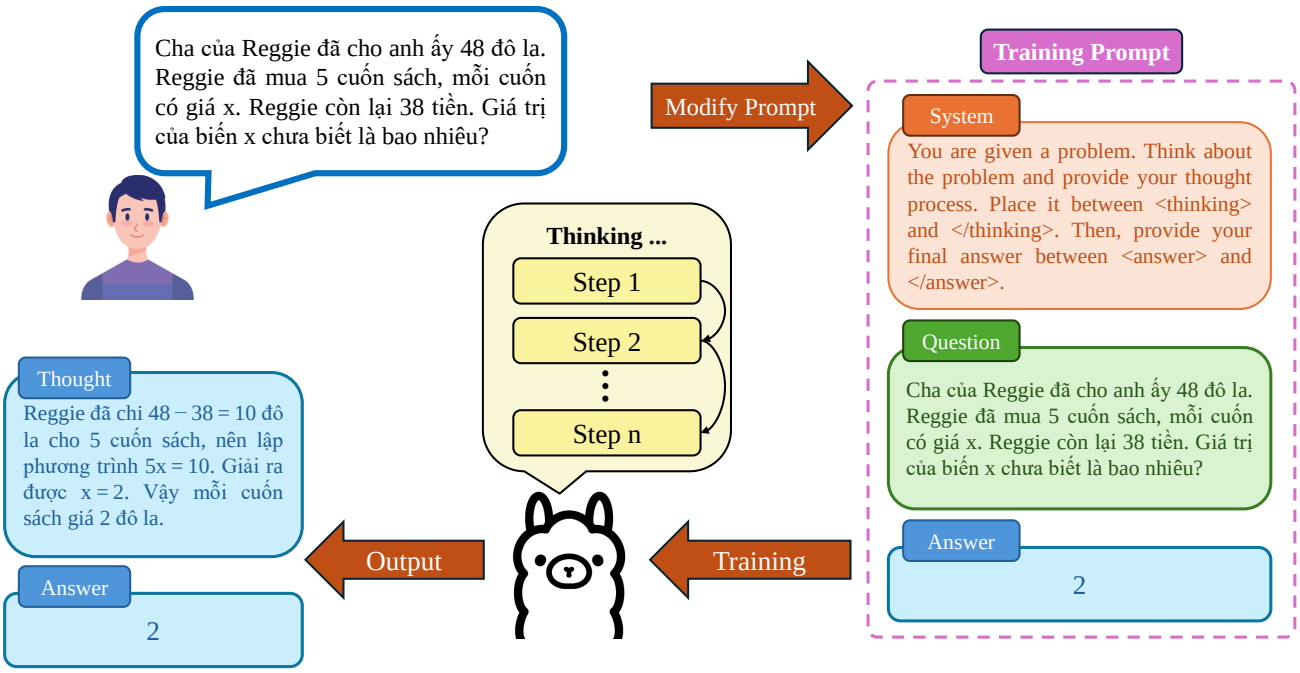

Hình 1: Huấn luyện mô hình ngôn ngữ lớn có khả năng suy luận với dữ liệu giải toán tiếng Việt.

Để tiện theo dõi, các bạn có thể tham khảo bảng các thuật ngữ được dùng trong bài tại Mục II.7.

Mục lục

I. Giới thiệu **1**

II. Cài đặt chương trình **5**

II.1. Cài đặt và import các thư viện cần thiết 5

II.2. Load mô hình lớn và setup cài đặt LoRA 5

II.3. Tải bộ dữ liệu 6

II.4. Cài đặt format prompt cho reasoning 7

II.5. Định nghĩa các hàm reward cho học tăng cường 9

II.6. Huấn luyện mô hình 12

II.7. Lưu trữ và inference 13

Bảng thuật ngữ **16**

Phụ lục **17**

Thay vì chỉ sinh văn bản mạch lạc dựa trên dữ liệu đã học, LLM Reasoning đòi hỏi mô hình "suy nghĩ từng bước" để đưa ra lời giải chính xác và giải thích chi tiết quá trình tư duy, đồng thời cải thiện tính minh bạch và độ tin cậy trên các nhiệm vụ như giải toán trắc nghiệm, lập luận khoa học hay phân tích ngữ nghĩa.

Trong bài viết này, chúng ta sẽ tìm hiểu cách cài đặt quá trình huấn luyện dựa trên thuật toán *Group Relative Policy Optimization (GRPO)* nhằm tăng cường khả năng suy luận cho một mô hình ngôn ngữ lớn thông qua dữ liệu các câu hỏi toán học. Mục tiêu là xây dựng một mô hình ngôn ngữ lớn chuyên cho việc giải toán trắc nghiệm tiếng Việt, không những có thể đưa ra đáp án đúng mà còn trình bày được chuỗi suy nghĩ logic dẫn đến đáp án đó (dẫn đến việc cải thiện hiệu suất mô hình). Bài toán được định nghĩa với đầu vào và đầu ra như sau:

- **Input:** Nội dung cụ thể của bài toán cần giải quyết.
- **Output:** Lời phản hồi từ mô hình, bao gồm quá trình suy nghĩ và đáp án cho câu hỏi.

Dựa vào nội dung mô tả trên, pipeline các bước xử lý trong bài này được minh họa theo hình dưới đây:

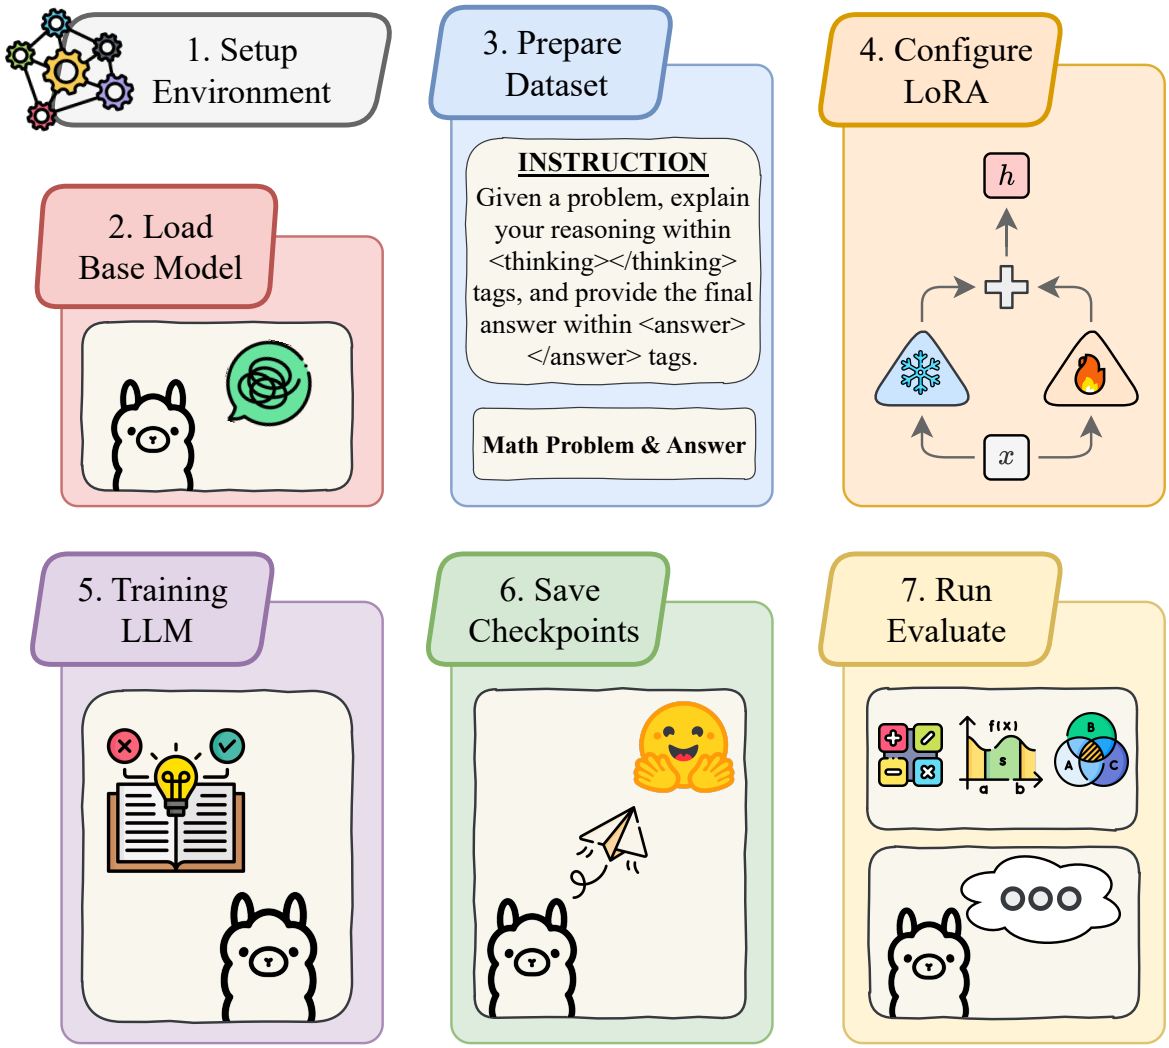

Hình 2: Pipeline huấn luyện LLM với GRPO.

Trong đó:

1. **Setup Environment:** Thiết lập môi trường làm việc, bao gồm cài đặt và import các thư viện phù hợp cho huấn luyện mô hình.
2. **Load Base Model:** Tải mô hình ngôn ngữ lớn (LLM) gốc từ thư viện như Hugging Face làm nền tảng để tinh chỉnh.
3. **Configure LoRA:** Cấu hình LoRA để giảm tài nguyên huấn luyện bằng cách khóa các tầng gốc và chỉ tinh chỉnh các adapter nhẹ.
4. **Prepare Dataset:** Chuẩn bị và tiền xử lí dữ liệu training bao gồm câu hỏi và đáp án đúng theo định dạng đầu vào/đầu ra rõ ràng.
5. **Fine-tune LLM:** Huấn luyện mô hình trên tập dữ liệu toán học đã chuẩn bị bằng GRPO và kỹ thuật LoRA nhằm tối ưu hiệu suất.
6. **Save Checkpoints:** Lưu lại các checkpoint của mô hình trong quá trình huấn luyện để theo dõi tiến độ và phục hồi nếu cần.
7. **Run Evaluate:** Thực hiện suy luận trên các câu hỏi để đánh giá khả năng đọc hiểu của mô hình sau tinh chỉnh.

Thông qua pipeline trên, ta sẽ có một mô hình ngôn ngữ lớn đã được tinh chỉnh với chi phí thấp, có khả năng suy luận và trả lời hiệu quả các câu hỏi toán học.

II. Cài đặt chương trình

II.1. Cài đặt và import các thư viện cần thiết

Đầu tiên, chúng ta cần cài đặt và nạp các thư viện hỗ trợ quá trình huấn luyện với GRPO và LoRA trên nền Llama 3.2 1B. Trong đó:

- `unsloth` cung cấp lớp `FastLanguageModel` tối ưu cho inference và fine-tuning.
- `vllm` hỗ trợ việc tạo sinh output nhanh chóng với cấu hình linh hoạt.
- `datasets` dùng để tải và xử lý tập dữ liệu MetaMathQA.
- `trl` bao gồm `GRPOConfig` và `GRPOTrainer` cho module học tăng cường.

Chúng ta thực hiện cài đặt `unsloth` và `vllm` thông qua lệnh `pip install` dưới đây:

```
!pip install unsloth vllm==0.7.3
```

Sau khi cài đặt xong, chúng ta import các thư viện cần thiết để thiết lập mô hình, xử lý dữ liệu và cấu hình GRPO:

```
import os
import re

from vllm import SamplingParams
from unsloth import FastLanguageModel
from datasets import load_dataset, Dataset
from trl import GRPOConfig, GRPOTrainer
```

II.2. Load mô hình lớn và setup cài đặt LoRA

Tiếp theo, chúng ta khởi tạo mô hình Llama 3.2 1B từ Unsloth và kích hoạt LoRA để giảm số tham số cần huấn luyện. Lưu ý rằng, các bạn hoàn toàn có thể thay đổi sang các phiên bản mô hình Llama 3.2 với số lượng tham số lớn hơn để có thể đạt một mô hình với hiệu suất cao hơn nếu phần cứng cho phép.

```
max_seq_length = 2048
lora_rank = 64

model, tokenizer = FastLanguageModel.from_pretrained(
    model_name="meta-llama/Llama-3.2-1B-Instruct",
    max_seq_length=max_seq_length,
    load_in_4bit=False,
```

```
    fast_inference=True,
    max_lora_rank=lora_rank,
    gpu_memory_utilization=0.8,
)

model = FastLanguageModel.get_peft_model(
    model,
    r=lora_rank,
    target_modules=[
        "q_proj", "k_proj", "v_proj", "o_proj",
        "gate_proj", "up_proj", "down_proj",
    ],
    lora_alpha=lora_rank,
    use_gradient_checkpointing="unsloth",
    random_state=3407,
)
```

- `max_seq_length` định nghĩa độ dài tối đa của input sequence.
- `lora_rank` xác định kích thước của ma trận adapter LoRA.
- `load_in_4bit=False` tắt lượng tử hóa để giữ độ chính xác cho reasoning.
- `fast_inference=True` tối ưu hóa throughput khi sinh text.
- `gpu_memory_utilization=0.8` cho phép sử dụng tối đa 80% bộ nhớ GPU.

II.3. Tải bộ dữ liệu

Trong bài này, ta sẽ tăng cường khả năng suy luận của mô hình LLM trong việc giải toán trắc nghiệm tiếng Việt. Theo đó, bộ dữ liệu MetaMathQA-40K phiên bản tiếng Việt sẽ được tải về thông qua đoạn code dưới đây:

```
dataset = load_dataset("5CD-AI/Vietnamese-meta-math-MetaMathQA-40K-gg-translated",
                                                    split="train")
```

Bài toán	**Đáp án**
Cha của Reggie đã cho anh ấy $48. Reggie mua 5 cuốn sách, mỗi cuốn giá $x và còn lại $38. Hỏi giá trị của $x là bao nhiêu?	2
Jean và ba người bạn chơi domino với bộ 28 quân, chia đều cho 4 người. Hỏi mỗi người nhận bao nhiêu quân?	7
Cally có 10 áo trắng, 5 áo màu, 7 quần đùi và 6 quần dài (tổng 28 bộ). Danny có 6 áo trắng, 8 áo màu, 10 quần đùi và 6 quần dài (tổng 30 bộ). Hỏi họ đã giặt bao nhiêu bộ quần áo?	58

Bảng 1: Một vài mẫu câu hỏi và đáp án trực tiếp (phần tiếng Việt) trong bộ MetaMathQA-40K.

II.4. Cài đặt format prompt cho reasoning

Trước khi huấn luyện, ta cần chuẩn hóa dữ liệu để mô hình học được chuỗi suy nghĩ và đáp án tách biệt. Các bước bao gồm:

1. Dùng regex `answer_pattern` để trích xuất đúng phần "đáp án là...".
2. Đánh dấu bắt đầu/kết thúc chuỗi suy nghĩ bằng `<thinking>`...`</thinking>` và phần đáp án bằng `<answer>`...`</answer>`.
3. Xây dựng `system_prompt` hướng dẫn model sinh reasoning rồi answer.
4. Chuyển danh sách thành `train_dataset` với hai trường `prompt` và `answer`.

<|begin_of_text|><|start_header_id|>system<|end_header_id|>

Cutting Knowledge Date: December 2023
Today Date: 28 Apr 2025

You are given a problem.
Think about the problem and provide your thought process.
Place it between <thinking> and </thinking>.
Then, provide your final answer between <SOLUTION></SOLUTION><|eot_id|>
<|start_header_id|>user<|end_header_id|>

Cha của Reggie đã cho anh ấy 48 đô la. Reggie đã mua 5 cuốn sách, mỗi cuốn có giá x. Reggie còn lại 38 tiền. Giá trị của biến x chưa biết là bao nhiêu?<|eot_id|>
<|start_header_id|>assistant<|end_header_id|>

Hình 3: Nội dung đầy đủ chi tiết của một mẫu prompt khi đưa vào mô hình Llama với một số thông tin về việc reasoning cũng như thông tin về bài toán.

```python
answer_pattern = re.compile(
    r"(đáp án là:|đáp án là :|câu trả lời là:|câu trả lời là :)\s*(.*)",
    re.IGNORECASE
)

formatted_dataset = []
for item in dataset:
    response = item["response_vi"].strip().lower()
    match = answer_pattern.search(response)
    if match:
        answer = match.group(2).strip()
        formatted_dataset.append({
            "question": item["query_vi"],
            "answer": answer
        })

reasoning_start = "<thinking>"
reasoning_end = "</thinking>"
solution_start = "<answer>"
solution_end = "</answer>"

system_prompt = \
    f"""You are given a problem.
Think about the problem and provide your thought process.
Place it between {reasoning_start} and {reasoning_end}.
Then, provide your final answer between {solution_start}{solution_end}"""
```

```python

train_dataset = Dataset.from_list(formatted_dataset[:8000])
train_dataset = train_dataset.map(lambda x: {
    "prompt": [
        {"role": "system", "content": system_prompt},
        {"role": "user",   "content": x["question"]},
    ],
    "answer": x["answer"],
})
```

II.5. Định nghĩa các hàm reward cho học tăng cường

Đối với các thuật toán học tăng cường, việc đánh giá hiệu suất mô hình thường được thông qua các hàm điểm thưởng (reward function). Trong trường hợp này, các hàm reward được cân nhắc triển khai đánh giá chất lượng output theo hai tiêu chí: đúng format reasoning và đúng đáp án. Các bạn hoàn toàn có thể tìm hiểu để đưa ra thêm các tiêu chí điểm thưởng phù hợp.

II.5.1. Reward cho output đúng format toán

Đầu tiên, ta tạo ra hai hàm có chức năng tính điểm cho mô hình nếu nó cho ra một format output phù hợp. Ở đây, ta có hàm `match_format_exactly()`, nếu hoàn toàn khớp pattern reasoning + answer, cộng 3.0 điểm. Bên cạnh đó, hàm `match_format_approximately()` sẽ kiểm tra số lượng tag xuất hiện, cộng 0.5 mỗi tag đúng, trừ 1.0 nếu không đúng.

```python
match_format = re.compile(
    rf"^[\s]{{0,}}"
    rf"{reasoning_start}.+?{reasoning_end}.*?"
    rf"{solution_start}(.+?){solution_end}"
    rf"[\s]{{0,}}\$",
    flags=re.MULTILINE | re.DOTALL
)

def match_format_exactly(completions, **kwargs):
    scores = []
    for completion in completions:
        score = 0
        response = completion[0]["content"]
        if match_format.search(response) is not None:
            score += 3.0
        scores.append(score)
    return scores

def match_format_approximately(completions, **kwargs):
    scores = []
    for completion in completions:
        score = 0
        response = completion[0]["content"]
```

```
        score += 0.5 if response.count(reasoning_start) == 1 else -1.0
        score += 0.5 if response.count(reasoning_end) == 1 else -1.0
        score += 0.5 if response.count(solution_start) == 1 else -1.0
        score += 0.5 if response.count(solution_end) == 1 else -1.0
        scores.append(score)
    return scores
```

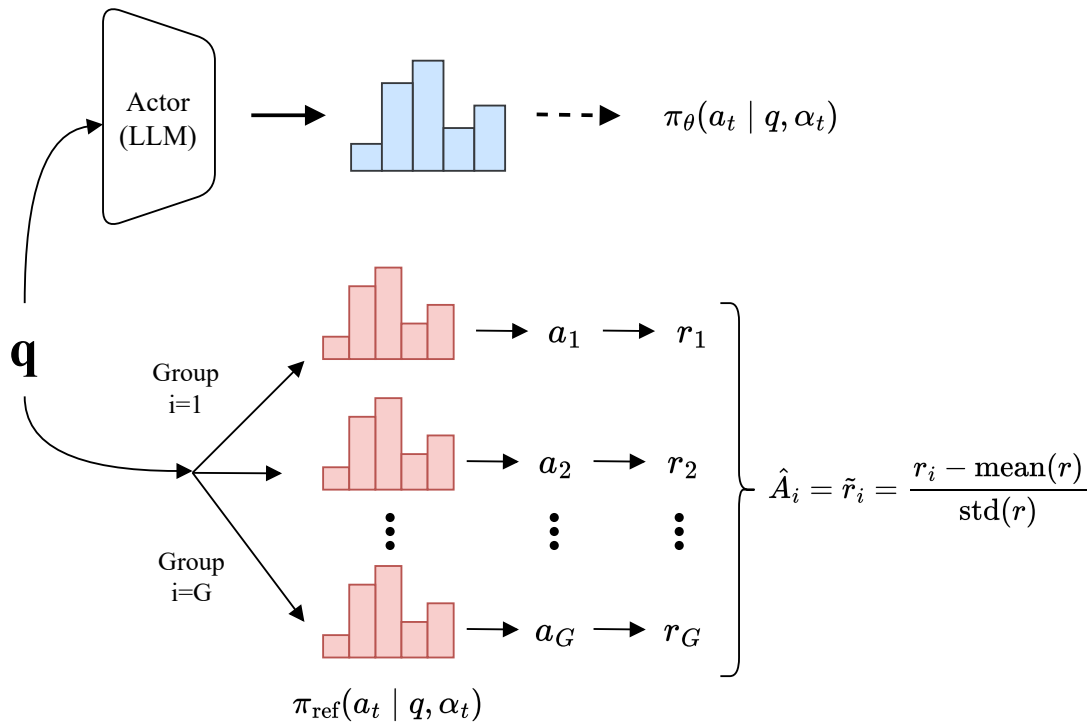

Hình 4: Minh họa quy trình GRPO, trong đó LLM đóng vai trò actor sinh phân phối xác suất cho hành động, sau đó lấy mẫu thành nhiều nhóm, đánh giá reward cho từng nhóm và chuẩn hóa kết quả để cập nhật chính sách.

II.5.2. Reward cho output đúng đáp án

Tiếp theo, ta định nghĩa hàm `check_answer()` để so khớp chuỗi giữa tag `<answer>`, cộng 3.0 nếu đúng, 1.5 nếu chỉ khác khoảng trắng, trừ 1.5 nếu sai hoàn toàn. Cuối cùng, ta có hàm `check_numbers()` với chức năng trích xuất số, so sánh giá trị float, cộng 1.5 nếu đúng, trừ 0.5 nếu sai.

```
match_numbers = re.compile(
    solution_start + r".*?([\d\.\,]{1,})",
    flags=re.MULTILINE | re.DOTALL
)

def check_answer(prompts, completions, answer, **kwargs):
```

```python
    responses = [completion[0]["content"] for completion in completions]

    extracted_responses = [
        guess.group(1)
        if (guess := match_format.search(r)) is not None else None
        for r in responses
    ]

    scores = []
    for guess, true_answer in zip(extracted_responses, answer):
        score = 0
        if guess is None:
            scores.append(0)
            continue
        if guess == true_answer:
            score += 3.0
        elif guess.strip() == true_answer.strip():
            score += 1.5
        else:
            score -= 1.5
        scores.append(score)
    return scores

def check_numbers(prompts, completions, answer, **kwargs):
    question = prompts[0][-1]["content"]
    responses = [completion[0]["content"] for completion in completions]

    extracted_responses = [
        guess.group(1)
        if (guess := match_numbers.search(r)) is not None else None
        for r in responses
    ]

    count = getattr(check_numbers, 'counter', 0) + 1
    check_numbers.counter = count
    if count % 5 == 0:
        print('*'*20, f"Question:{question}", f"\nResponse:\n{responses[0]}",
              f"\nExtracted: {extracted_responses[0]}", f"\nGT Answer: {answer[0]}")

    scores = []
    for guess, true_answer in zip(extracted_responses, answer):
        if guess is None:
            scores.append(0)
            continue
        try:
            true_answer = float(true_answer.strip())
            # Remove commas like in 123,456
            guess = float(guess.strip().replace(",", ""))
            scores.append(1.5 if guess == true_answer else -0.5)
        except:
            scores.append(0)
    return scores
```

II.6. Huấn luyện mô hình

Với tất cả các thông tin trên mà chúng ta đã khai báo, để tiến hành huấn luyện, ta chỉ cần cấu hình và chạy GRPOTrainer để thực hiện training học tăng cường với các hàm reward đã xây dựng:

```python
max_len = max(train_dataset.map(
    lambda x: {"tokens": tokenizer.apply_chat_template(
        x["prompt"], add_generation_prompt=True, tokenize=True)},
    batched=True,
).map(lambda x: {"length": len(x["tokens"])})["length"])

max_prompt_length = max_len + 1

training_args = GRPOConfig(
    learning_rate=5e-6,
    weight_decay=5e-4,
    warmup_ratio=0.1,
    lr_scheduler_type="cosine",
    optim="adamw_torch_fused",
    logging_steps=1,
    per_device_train_batch_size=2,
    gradient_accumulation_steps=64,
    num_generations=8,
    max_prompt_length=max_prompt_length,
    max_completion_length=max_seq_length - max_prompt_length,
    num_train_epochs=1,
    max_steps=-1,
    save_steps=250,
    max_grad_norm=0.1,
    report_to="wandb",
    output_dir="outputs_bz2",
)

trainer = GRPOTrainer(
    model=model,
    processing_class=tokenizer,
    reward_funcs=[
        match_format_exactly,
        match_format_approximately,
        check_answer,
        check_numbers,
    ],
    args=training_args,
    train_dataset=train_dataset,
)
trainer.train()
```

- Tính `max_prompt_length()` dựa trên độ dài token tối đa của prompt đã format.
- Cấu hình `GRPOConfig` với learning rate, weight decay, warmup ratio, scheduler cosine, batch size, số lượng generations, gradient accumulation, và các bước lưu checkpoint.

- Khởi tạo `GRPOTrainer` với danh sách các hàm reward và dataset phù hợp.
- Gọi `trainer.train()` để bắt đầu huấn luyện.

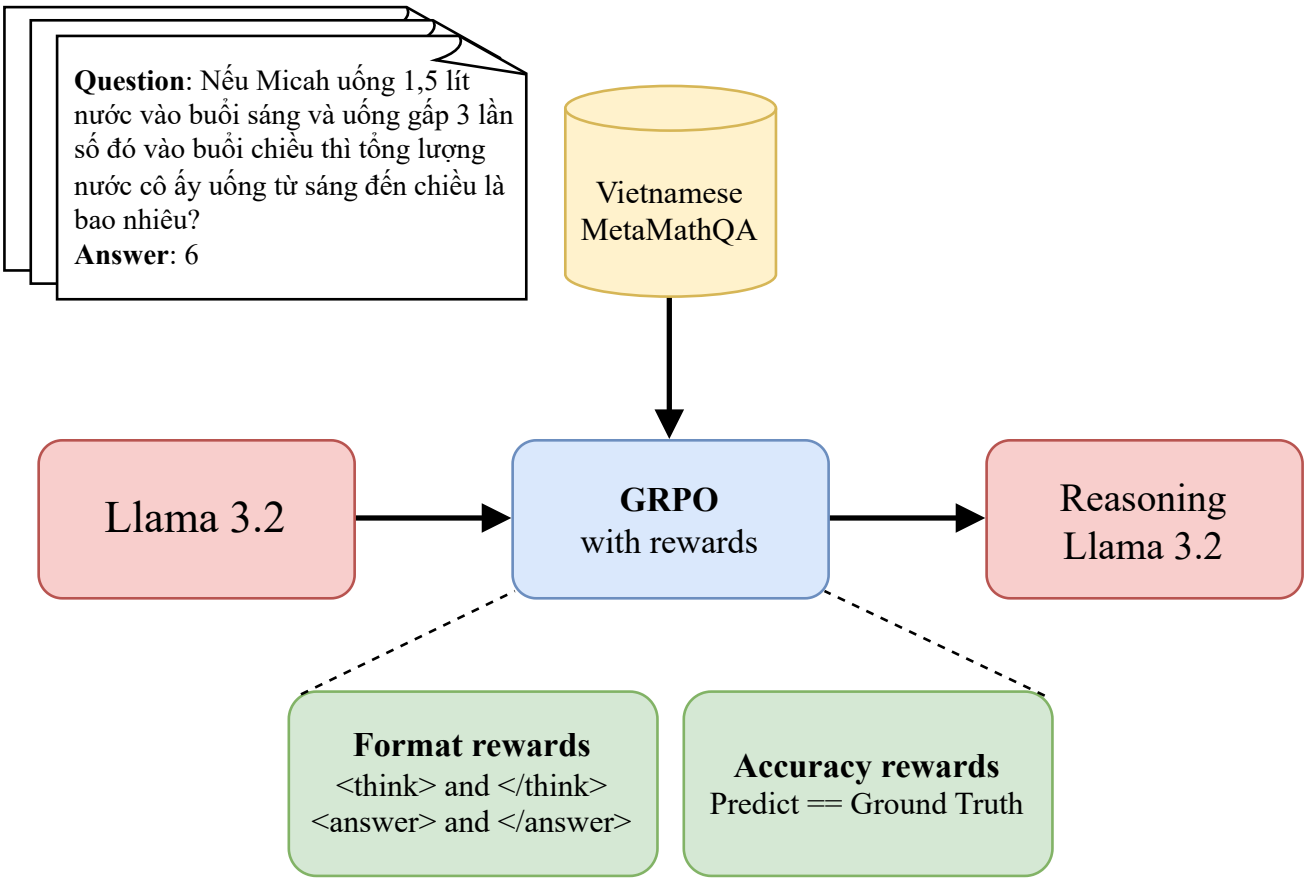

Hình 5: Sử dụng thuật toán học tăng cường GRPO nhằm khuyến khích việc đưa ra các suy luận trước khi tạo sinh phương án cuối cùng của mô hình Llama.

II.7. Lưu trữ và inference

Sau khi huấn luyện xong, ta lưu adapter LoRA đã học và tiến hành thử suy luận trên một ví dụ:

```
model.save_lora("grpo_saved_lora")
```

```
idx = 0
messages = [
    {"role": "system", "content": system_prompt},
    {"role": "user",   "content": train_dataset[idx]["question"]},
]
sampling_params = SamplingParams(
    temperature = 0.8,
```

```python
    top_p = 0.95,
    max_tokens = 1024,
)

text = tokenizer.apply_chat_template(
    messages,
    add_generation_prompt = True,
    tokenize = False,
)

path_lora = "grpo_saved_lora"
output = model.fast_generate(
    [text],
    sampling_params = sampling_params,
    lora_request = model.load_lora(path_lora),
)[0].outputs[0].text

print(f"Problem:\n{train_dataset[idx]['question']}")
print(f"Response:\n{output}")
print("GT Answer:", train_dataset[idx]["answer"])
```

<thinking>
Để tìm giá trị của x, ta cần hiểu rằng Reggie đã chi một khoản tiền 48 - 38 = 10 đô la để mua các sách. Vì Reggie đã mua 5 cuốn sách với giá x mỗi cuốn nên ta có thể tạo ra một công thức để tính tổng chi phí mua sách: 5x = 10.

Để giải quyết cho x, ta chia cả hai bên của công thức bằng 5: x = 10 / 5.

Solvers lại ta có: x = 2.
Vậy giá của mỗi cuốn sách là 2 đô la.
</thinking>
<SOLUTION>2**</SOLUTION>**

Hình 6: Minh họa một kết quả tạo sinh của mô hình với phần reasoning và đáp án cuối cùng.

Ví dụ minh họa ở Hình 6 cho thấy Llama 3.2 1B sau khi được tinh chỉnh với GRPO và LoRA đã có khả năng sinh chuỗi suy nghĩ chi tiết bằng thẻ `<thinking>` trước khi đưa ra đáp án cuối cùng trong thẻ `<answer>`. Điều này khẳng định tính hiệu quả của việc kết hợp học tăng cường và kỹ thuật LoRA, không chỉ nâng cao độ chính xác mà còn cải thiện tính giải thích được (explainability) cho các nhiệm vụ yêu cầu tư duy logic chặt chẽ. Theo đó, các bạn hoàn toàn có

thể mở rộng phương pháp này cho các bài toán phức tạp hơn hoặc kết hợp thêm các tín hiệu đánh giá đa dạng để tiếp tục tối ưu khả năng suy luận của LLMs.

Bảng thuật ngữ

Thuật ngữ	Tạm dịch	Mô tả
Base Model	Mô hình nền tảng	Mô hình ngôn ngữ lớn (LLM) đã được huấn luyện trước trên một lượng dữ liệu khổng lồ, đóng vai trò là điểm khởi đầu để thực hiện các quá trình tinh chỉnh (Fine-tuning) chuyên biệt.
Chain-of-Thought (CoT)	Chuỗi suy nghĩ	Quá trình mô hình liệt kê các bước lập luận logic từng bước một để giải quyết vấn đề phức tạp thay vì chỉ đưa ra đáp án cuối cùng ngay lập tức.
Checkpoints	Điểm kiểm soát	Các trạng thái lưu trữ tạm thời của trọng số mô hình trong quá trình huấn luyện, cho phép phục hồi hoặc đánh giá mô hình tại các giai đoạn khác nhau.
Group Relative Policy Optimization (GRPO)	Tối ưu hóa chính sách tương đối theo nhóm	Một thuật toán học tăng cường (Reinforcement Learning) do DeepSeek phát triển, giúp tối ưu hóa mô hình bằng cách so sánh kết quả của một nhóm các mẫu thử thay vì sử dụng một mô hình Critic riêng biệt.
Low-Rank Adaptation (LoRA)	Thích ứng thứ hạng thấp	Kỹ thuật tinh chỉnh mô hình (Fine-tuning) hiệu quả về tài nguyên bằng cách đóng băng các tham số gốc và chỉ huấn luyện một số lượng nhỏ các ma trận bổ trợ.
Reasoning LLM	Mô hình ngôn ngữ suy luận	Một hệ quản trị hoặc lớp các mô hình ngôn ngữ lớn được thiết kế để không chỉ đưa ra kết quả mà còn có khả năng thực hiện các bước tư duy logic trung gian (Chain-of-Thought) trước khi trả lời.
Reinforcement Learning (RL)	Học tăng cường	Một phương pháp học máy trong đó mô hình (Agent) học cách thực hiện các hành động để tối đa hóa tổng số điểm thưởng (Reward) nhận được từ môi trường.
Reward Function	Hàm điểm thưởng	Thành phần cốt lõi trong học tăng cường, đóng vai trò như một "giám khảo" để chấm điểm đầu ra của mô hình dựa trên các tiêu chí như độ chính xác, định dạng hoặc tính logic.

Phụ lục

1. **Resources:** Các file dataset, code gợi ý (hint) và bài giải (solution) có thể được tải tại đây.

2. **Rubric:**

Mục	Kiến Thức	Đánh Giá
I.	- Kiến thức về mô hình lớn (LLMs). - Kiến thức về học tăng cường cơ bản và thuật toán học tăng cường GRPO. - Khái niệm về Reasoning trong mô hình lớn và các cách thức kích hoạt khả năng này cho mô hình lớn. - Kiến thức về thư viện PyTorch và HuggingFace. - Triển khai PEFT (LoRA) và thiết lập các tham số liên quan đến LoRA.	- Nắm được lý thuyết về khả năng suy luận của mô hình lớn (LLM Reasoning). - Hiểu được cơ bản về lý thuyết học tăng cường cũng như thuật toán GRPO được ứng dụng. - Nắm được lý thuyết cơ bản về kỹ thuật LoRA. - Có khả năng cài đặt và thực hiện huấn luyện học tăng cường mô hình lớn trên một bộ dữ liệu bất kì nhằm cải thiện khả năng suy luận của một mô hình ngôn ngữ lớn.

3. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 tiếng.

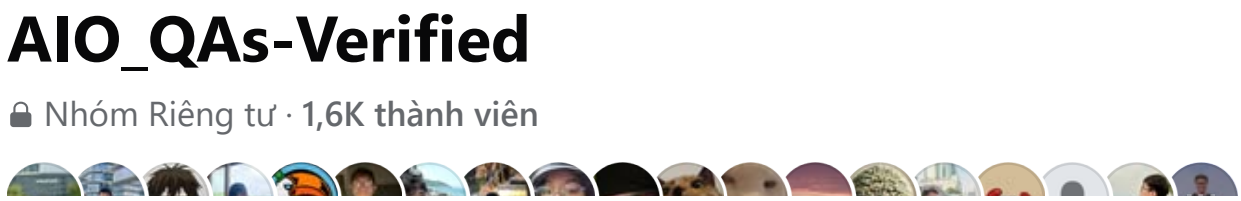

Hình 7: Hình ảnh group facebook AIO Q&A.

- Hết -